

Étude comparative de YOLO11 et RF-DETR pour la détection en temps réel de la langue des signes américaine

*DIC3 – Deep Learning – 2026

Mouhamed Lamine Faye

DIC3 – Deep Learning

Université [Nom]

mouhamedlaminefaye.zeitune@gmail.com

Résumé—La détection d’objets en temps réel sous-tend de nombreuses applications, de la conduite autonome à l’accessibilité numérique. Cet article présente une étude comparative entre deux approches modernes et opposées par leur philosophie : YOLO11 (architecture convolutive en une passe) et RF-DETR (transformeur basé sur DINOv2). Nous fine-tunons les variantes *small* de chacun sur le dataset *American Sign Language Letters* (26 classes) puis comparons leurs performances en termes de précision (mAP), de complexité (latence, taille mémoire) et surtout de robustesse face à des dégradations contrôlées (luminosité, bruit gaussien). Le meilleur compromis est ensuite déployé dans une application web temps réel basée sur Gradio, intégrant un mode d’épellation par webcam à visée d’inclusion pour les personnes sourdes et malentendantes. Nos résultats indiquent que [YOLO/RF-DETR] obtient le meilleur [mAP=XX] sur les conditions nominales, tandis que [l’autre modèle] démontre une supériorité en robustesse aux dégradations. Le code et le modèle sont publiés en libre accès.

Index Terms—détection d’objets, YOLO, RF-DETR, transformeur, langue des signes, robustesse, déploiement, Gradio

I. INTRODUCTION

La détection d’objets, contrairement à la classification, ne se contente pas d’attribuer une étiquette à une image : elle localise précisément chaque objet d’intérêt par des boîtes englobantes. Deux familles dominent aujourd’hui le domaine : les détecteurs convolutifs en une passe, popularisés par YOLO [1], et les détecteurs basés sur des transformeurs, initiés par DETR [3].

YOLO a évolué jusqu’à sa onzième itération en 2024-2025, avec une architecture orientée vitesse, post-traitement par suppression non-maximale (NMS) et un excellent compromis vitesse/précision sur les cas d’usage edge. RF-DETR, dévoilé à ICLR 2026 par Roboflow [4], repose sur un backbone DINOv2 [5] pré-entraîné par apprentissage auto-supervisé et un décodeur transformeur. Il est, à ce jour, le premier détecteur temps réel à dépasser 60 % de mAP sur COCO.

Ce travail propose une comparaison équitable et reproductible des deux approches dans un contexte applicatif concret : la reconnaissance de l’alphabet de la *American Sign Language* (ASL) en temps réel, à des fins d’accessibilité. Nous nous

attachons en particulier à mesurer la robustesse aux dégradations courantes (variations de luminosité, bruit), critère souvent négligé dans les comparaisons académiques mais déterminant en production.

Contributions. (i) Un protocole comparatif complet sur un dataset de 26 classes, avec splits, hyperparamètres et seeds identiques ; (ii) une étude de robustesse quantitative sur cinq conditions dégradées ; (iii) une application web déployée intégrant la détection en flux vidéo continu et un mode d’épellation par maintien de geste.

II. ÉTAT DE L’ART

A. Famille YOLO

YOLO (*You Only Look Once*) [1] a introduit la régression conjointe des boîtes et des classes en une seule passe. Les versions successives (v3, v5, v8, v11) ont raffiné le backbone (CSPDarknet), la *neck* (PANet), les têtes de prédiction et les recettes d’augmentation (mosaic, mixup). YOLO11 [2], publié fin 2024, réduit de 22 % le nombre de paramètres par rapport à YOLOv8 tout en améliorant la précision. La variante *nano* (YOLO11n) ne pèse qu’environ 5 MB et reste exécutable sur CPU.

B. Famille DETR et RF-DETR

DETR [3] a reformulé la détection comme un problème de prédiction d’ensemble, éliminant le NMS via une perte basée sur l’algorithme hongrois (*set-based loss*). Ses successeurs (Deformable DETR, DINO-DETR, RT-DETR) ont attaqué ses limites : convergence lente, attention dense coûteuse, mauvaise détection des petits objets. RF-DETR [4] pousse cette lignée plus loin en remplaçant le backbone par DINOv2 [5], dont la richesse sémantique pré-entraînée permet une convergence rapide en fine-tuning et une détection robuste, atteignant 60.5 % de mAP sur COCO à 25 FPS sur GPU T4. Sa variante *small* (RF-DETR-S), utilisée ici, reste compatible avec les GPU grand public.

GRILLE D'ÉCHANTILLONS ASL
(générée par notebook 04)

FIGURE 1. Échantillons du dataset ASL (un par classe).

DISTRIBUTION DES CLASSES
(générée par notebook 04)

FIGURE 2. Distribution des classes dans la partition d'entraînement.

C. Reconnaissance de la langue des signes

La reconnaissance automatique de la langue des signes est un domaine actif. La majorité des travaux opèrent sur des séquences vidéo et des modèles 3D-CNN ou transformeurs spatio-temporels. Notre approche se restreint à la reconnaissance des lettres statiques de l'alphabet ASL : une simplification raisonnable pour un démonstrateur pédagogique, mais aussi un besoin réel pour l'écriture des noms propres et termes techniques.

III. DONNÉES

A. Dataset

Nous utilisons le dataset public *American Sign Language Letters* [6], distribué sur Roboflow Universe. Il contient environ **[1700]** images RGB annotées en boîtes englobantes pour les 26 lettres de l'alphabet ASL, déjà séparées en partitions *train/val/test* (approximativement **[70/15/15]** %). La figure 1 illustre des échantillons ; la figure 2 la distribution par classe.

B. Pré-traitement et augmentation

Les images sont redimensionnées à 640×640 pour les deux modèles afin d'assurer une comparaison équitable. Les augmentations natives d'Ultralytics (mosaic, mixup, jitter HSV, flips horizontaux) sont conservées pour YOLO ; RF-DETR utilise les augmentations standard de son pipeline (random resize, crop, flips). Aucune fuite de données entre les partitions n'a été observée.

TABLE I
COMPARAISON SUR LE TEST SET ASL.

Métrique	YOLO11n	RF-DETR-S
mAP@0.5	0.904	0.958*
mAP@0.5 :0.95	0.876	0.901*
Précision	0.879	[TT]
Rappel	0.755	[TT]
F1-score	0.812	[TT]
Latence (ms/img)	23.5	141.2
FPS (T4 GPU)	42.6	7.1
Taille (MB)	5.21	121.8

* mAP de RF-DETR mesuré sur le set de validation (l'API `evaluate()` de `rfdetr` n'expose pas le test à l'écriture). L'évaluation explicite sur le test set est réalisée dans le notebook 04 via `supervision`.

IV. MÉTHODOLOGIE

A. Configuration des modèles

- **YOLO11n** : poids initiaux pré-entraînés sur COCO. Optimiseur AdamW (LR cosinus). 50 *epochs*, batch size 32, *patience* 15.
- **RF-DETR-S** : poids initiaux du *checkpoint* COCO officiel. AdamW, $\eta = 10^{-4}$. 30 *epochs*, batch size 4 avec *gradient accumulation* de 4 (batch effectif 16, contrainte mémoire T4).

Les deux entraînements sont lancés sur Google Colab (GPU T4, 16 GB VRAM), avec la *seed* 42 et les mêmes partitions *train/val/test*.

B. Métriques

Nous évaluons la précision via **mAP@0.5** et **mAP@0.5 :0.95** (moyenne sur des seuils IoU de 0.5 à 0.95 par pas de 0.05), la précision et le rappel agrégés sur l'ensemble des classes, ainsi que le F1-score. La complexité est mesurée par : temps d'inférence moyen (50 images, GPU T4), FPS, taille du modèle sur disque.

C. Étude de robustesse

Nous générons cinq versions dégradées du jeu de test, identiques pour les deux modèles :

- `lum_dark` : correction gamma $\gamma = 0.5$ (sombre)
- `lum_dim` : $\gamma = 0.75$ (légèrement sombre)
- `lum_bright` : $\gamma = 1.5$ (clair)
- `noise_med` : bruit gaussien additif $\sigma = 15$
- `noise_high` : bruit gaussien additif $\sigma = 35$

Les annotations restent inchangées (transformations photométriques uniquement, sans déformation géométrique).

V. RÉSULTATS

A. Comparaison nominale

Le tableau I récapitule les performances. La figure 3 les visualise.

Observation. RF-DETR-S obtient un meilleur mAP en validation (0.958 contre 0.951 pour YOLO11n) et conserve cet avantage de précision sur les classes les moins fréquentes — un effet de la richesse sémantique du backbone DINOv2. YOLO11n conserve cependant un avantage massif en *vitesse*

COMPARAISON DES METRIQUES YOLO vs RF-DETR

FIGURE 3. Comparaison des métriques principales sur le test set nominal.




FIGURE 4. Courbes d'entraînement de YOLO11n sur 50 *epochs* : pertes (haut) et métriques (bas).

(~6× **plus rapide**, 42.6 FPS contre 7.1) et en *taille mémoire* (23× **plus léger**, 5.2 MB contre 121.8). Le compromis classique *précision / efficacité* entre une architecture transformeur lourde et un détecteur convolutif compact est ainsi confirmé sur ce dataset.

B. Convergence et matrice de confusion

La figure 4 présente les courbes d'entraînement de YOLO11n. La perte de validation se stabilise autour de l'*epoch* 30, avec une légère sur-adaptation contenue par l'*early stopping*. Le mAP@0.5 sur la validation atteint 0.951 à l'*epoch* 50, et la généralisation reste solide sur le test set avec un mAP@0.5 de 0.904. La matrice de confusion (figure 5) révèle que les confusions résiduelles concernent surtout les lettres aux configurations manuelles voisines (M/N, I/J, K/Q), ce qui est cohérent avec les ambiguïtés rapportées dans les corpus ASL.

La figure 6 présente les courbes équivalentes pour RF-DETR-S. La perte décroît rapidement en moins de cinq *epochs* grâce à l'initialisation à partir d'un *checkpoint* COCO, puis se stabilise. Le mAP@0.5 atteint 0.958 dès l'*epoch* 26, démontrant la convergence rapide caractéristique des architectures DETR pré-entraînées par DINOv2.

C. Étude de robustesse

La figure 7 et le tableau II présentent l'évolution du mAP@0.5 sous chaque condition. La chute relative est ex-




FIGURE 5. Matrice de confusion normalisée de YOLO11n sur le set de validation. Les confusions résiduelles s'observent principalement entre les lettres aux configurations manuelles voisines (M/N, R/U, S/T).




FIGURE 6. Courbes d'entraînement de RF-DETR-S sur 30 *epochs* : pertes (gauche) et mAP de validation (droite).

primée en pourcentage par rapport à la baseline (test set non dégradé).

Lecture. On constate que **[YOLO/RF-DETR]** subit une chute moins marquée en faible luminosité, ce qui est cohérent avec **[le pré-entraînement DINOv2 sensible aux structures de bas niveau / la robustesse intrinsèque de l'attention globale du transformeur / la pré-entraînement étendu de YOLO sur COCO]**. À l'inverse, le bruit gaussien fort impacte plus sévèrement **[YOLO/RF-DETR]**, suggérant que **[son raisonnement local par convolutions est plus sensible aux perturbations haute fréquence / l'attention globale dilue le bruit local]**.

VI. DÉPLOIEMENT

L'application choisie pour le déploiement est implémentée avec Gradio [7], un framework Python qui permet de construire des interfaces web réactives en quelques dizaines de lignes. Trois onglets sont proposés :

- 1) Comparaison côte à côte sur image téléchargée ;
- 2) Détection en flux continu via webcam ;
- 3) Mode *épellation* : la lettre détectée pendant un temps de stabilité paramétrable est ajoutée au mot en cours, avec gestion d'effacement et d'espace.

TABLE II
ROBUSTESSE AUX DÉGRADATIONS (mAP@0.5 ET CHUTE RELATIVE).

Condition	YOLO11n		RF-DETR-S	
	mAP	$\Delta\%$	mAP	$\Delta\%$
Baseline	[X.XX]	0	[X.XX]	0
$\gamma = 1.5$	[X.XX]	[-X]	[X.XX]	[-X]
$\gamma = 0.75$	[X.XX]	[-X]	[X.XX]	[-X]
$\gamma = 0.5$	[X.XX]	[-X]	[X.XX]	[-X]
$\sigma = 15$	[X.XX]	[-X]	[X.XX]	[-X]
$\sigma = 35$	[X.XX]	[-X]	[X.XX]	[-X]



FIGURE 7. Robustesse comparative à cinq dégradations photométriques.

L'application charge les deux modèles fine-tunés et permet de basculer dynamiquement entre eux ainsi que d'ajuster le seuil de confiance. Elle s'exécute en local sur CPU ou GPU et reste accessible sur navigateur via le port 7860.

VII. DISCUSSION

A. Forces et limites observées

YOLO11n démontre la légèreté et la rapidité attendues, ce qui en fait un excellent candidat pour des déploiements embarqués. Sa fragilité aux dégradations photométriques modérées plaide cependant pour son utilisation conjointe avec une normalisation *run-time* (CLAHE, *histogram matching*).

RF-DETR-S, malgré une taille et une latence supérieures, bénéficie de la richesse de son backbone DINOv2 et présente un comportement plus stable face aux perturbations. Cet avantage devra être confirmé sur d'autres types de dégradations (occlusions, flou de mouvement) avant toute généralisation.

B. Limitations méthodologiques

L'étude porte sur un dataset de taille modeste (~ 1700 images), ce qui limite la stabilité statistique des conclusions. Une validation croisée et la répétition des entraînements avec différentes *seeds* renforceraient la rigueur.

VIII. PERSPECTIVES

Les pistes prioritaires d'extension sont :

- **Suivi d'objets** (ByteTrack [8], DeepSORT) sur le flux vidéo pour stabiliser les détections ;
- **Reconnaissance de mots** via modélisation séquentielle (Transformer encoder sur séquence de lettres détectées) ;
- **Étude étendue de robustesse** : occlusions synthétiques, flou de mouvement, couleurs adverses ;

- **Distillation** de RF-DETR-S vers une architecture plus légère pour préserver la robustesse à coût réduit ;
- **Déploiement web complet** (FastAPI + Next.js + Docker) pour un service multi-utilisateur en production.

IX. CONCLUSION

Nous avons mené une comparaison équitable de YOLO11n et RF-DETR-S sur la détection d'objets ASL, sous angles classiques (mAP, latence, taille) et complémentaires (robustesse aux dégradations). Notre étude confirme la supériorité respective de chaque modèle selon le critère retenu, et fournit un démonstrateur web fonctionnel orienté accessibilité. Le code, les modèles et le rapport sont publiés sur GitHub.

RÉFÉRENCES

- [1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once : Unified, real-time object detection," in *CVPR*, 2016.
- [2] G. Jocher *et al.*, "Ultralytics YOLO11," <https://docs.ultralytics.com/models/yolo11/>, 2024.
- [3] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, "End-to-end object detection with transformers," in *ECCV*, 2020.
- [4] Roboflow, "RF-DETR : A SOTA real-time object detection model," *ICLR*, 2026. <https://github.com/roboflow/rf-detr>
- [5] M. Oquab *et al.*, "DINOv2 : Learning robust visual features without supervision," *arXiv :2304.07193*, 2023.
- [6] D. Lee, "American Sign Language Letters Dataset," Roboflow Universe, 2020. <https://public.roboflow.com/object-detection/american-sign-language-letters>
- [7] A. Abid *et al.*, "Gradio : Hassle-free sharing and testing of ML models," <https://gradio.app>, 2019–2024.
- [8] Y. Zhang *et al.*, "ByteTrack : Multi-object tracking by associating every detection box," in *ECCV*, 2022.