

Détection d'objets en temps réel

Étude comparative YOLO11n vs RF-DETR-S

Application à la langue des signes américaine (ASL)

Mouhamed Lamine Faye Pape Moussa Mbengue Mouhamadou Wally Ndour

9 mai 2026

DIC3 – Génie Informatique

École Supérieure Polytechnique

Université Cheikh Anta Diop de Dakar

Contexte & Problématique

Dataset & Méthodologie

Résultats


Démonstration

Conclusion

Contexte & Problématique

Pourquoi la détection d'objets ?

- La **détection** localise et classe simultanément (vs classification simple).
- Deux familles dominantes :
 - CNN one-shot (*YOLO*) : rapidité.
 - Transformeurs (*DETR* / *RF-DETR*) : précision & robustesse.
- Mais comment choisir en pratique ?



Échantillons du dataset ASL

Reconnaissance des 26 lettres ASL

- Application d'**accessibilité** pour personnes sourdes/malentendantes.
- Démo **webcam temps réel** : épellation par geste.



26 lettres signées


Question de recherche

Sur un dataset modeste (1700 images, 26 classes), quel modèle offre le meilleur **compromis** précision / vitesse / **robustesse** ?

Dataset & Méthodologie

Dataset — American Sign Language Letters

- Source : Roboflow Universe (David Lee).
- 1 720 images en RGB, 26 classes.
- Splits **train** / **valid** / **test** : 504 / 144 / 72.
- Format : YOLO + COCO.
- Augmentations natives (mosaic, flips, jitter HSV).



Distribution des classes — train set

YOLO11n — Ultralytics (2024)

- CNN one-shot (CSPDarknet + PANet).
- NMS post-traitement.
- Variante *nano* : 2.6 M paramètres, ~5 MB.
- Pré-entraîné COCO.

RF-DETR-S — Roboflow (ICLR 2026)

- Transformeur à backbone **DINOv2**.
- Pas de NMS (*set prediction*).
- Variante *small* : ~30 M paramètres, ~122 MB.
- SOTA sur COCO (>60 mAP).

Comparaison équitable : mêmes splits, seed 42, 640×640 .

Entraînement (Google Colab T4)



- YOLO : 50 epochs, batch 32.
- RF-DETR : 30 epochs, batch 4 ($\times 4$ grad accum).
- Optimiseur AdamW, LR cosinus.

Évaluation

- Précision : mAP@0.5, mAP@0.5 : 0.95, P, R, F1.
- Complexité : latence, FPS, taille.
- **Robustesse** : 5 dégradations photométriques :
 - Luminosité $\gamma \in \{0.5, 0.75, 1.5\}$
 - Bruit gaussien $\sigma \in \{15, 35\}$

Résultats


Convergence des modèles



Les deux modèles convergent rapidement grâce au pré-entraînement COCO.

Performance — test set (72 images)


Métrique	YOLO11n	RF-DETR-S
mAP@0.5	0.904	0.901
mAP@0.5 :0.95	0.875	0.881
Précision	0.879	—
Rappel	0.755	—
F1-score	0.812	—
Latence (T4)	36.4 ms	132.8 ms
FPS	27.5	7.5
Taille	5.2 MB	121.8 MB



Observation

Précision quasi identique ; YOLO est $\sim 3.6\times$ plus rapide et $23\times$ plus léger.

Étude de robustesse — point fort



mAP@0.5 sous chaque condition dégradée

Cond.	YOLO $\Delta\%$	RF-DETR $\Delta\%$
$\gamma = 1.5$	+1.3	+0.8
$\gamma = 0.75$	-1.0	-0.8
$\gamma = 0.5$	-3.5	-0.8
$\sigma = 15$	-2.1	+0.1
$\sigma = 35$	-76.8	-1.1
Moy. $ \Delta $	16.9 %	0.7 %

Découverte clé

RF-DETR-S est dramatiquement plus robuste. YOLO s'effondre à 0.21 mAP sous bruit fort, RF-DETR reste à 0.89.

YOLO — convolutions locales

- Raisonne par **voisinages locaux**.
- Sensible aux perturbations **haute fréquence**.
- Effondrement quand le bruit masque les contours.

RF-DETR — attention globale

- Attention sur **toute l'image**.
- Backbone **DINOv2** pré-entraîné par auto-supervision.
- Représentations sémantiques **stables** face au bruit.

Démonstration

- **Alphabet ASL** : grille de référence des 26 signes.
- **Comparaison sur image** : YOLO + RF-DETR côte à côte.
- **Webcam temps réel** : détection live à 27 FPS (YOLO).
- **Épellation** : maintenir un signe pour l'ajouter au mot.

Démo live sur <http://localhost:7860>

Conclusion

Choisir YOLO11n quand...

- Conditions de capture maîtrisées.
- Cible **embarquée** ou **edge** (mobile, navigateur).
- Besoin de fluidité > 25 FPS.
- Notre cas pour la **démo webcam**.

Choisir RF-DETR-S quand...

- Environnement non maîtrisé : surveillance, extérieur.
- Capteurs bruités, faible luminosité.
- GPU disponible côté serveur.
- Précision robuste prioritaire.

À retenir

- Précision **nominale comparable** (mAP@0.5 : 0.904 vs 0.901).
- **YOLO** = vitesse & légèreté ; **RF-DETR** = robustesse.
- Le choix dépend du **contexte de déploiement**.

Perspectives

- **Suivi** d'objets vidéo (ByteTrack) pour stabiliser la détection.
- Reconnaissance de **mots** via modèle séquentiel.
- Élargir l'étude de robustesse (occlusions, flou de mouvement).
- **Distillation** de RF-DETR vers une variante plus légère.

Merci pour votre attention.

Questions ?

Code : `github.com/lamine-f/asl-detection-yolo-rfdetr`

Modèles : `huggingface.co/lamine-f-edu/asl-yolo-rfdetr`